Descripción Módulo De La Unidad 1

1. Introducción a la Ciencia de Datos

La ciencia de datos se define como un campo interdisciplinario que integra la estadística, la informática y los métodos de análisis de datos con el objetivo de extraer valor y conocimiento útil de conjuntos de datos complejos. Esta disciplina proporciona las herramientas necesarias para la resolución de problemas reales y la toma de decisiones fundamentadas en evidencia, lo cual es una competencia crítica en la era actual del Big Data y la analítica avanzada.

La evolución de este campo ha sido acelerada, pasando de la minería de datos y la estadística tradicional hacia entornos que integran aprendizaje automático (machine learning) y visualización interactiva. Su relevancia actual se refleja en su adopción masiva en sectores diversos como las finanzas, la salud y los negocios digitales.

1.1 Definición y Evolución

Entender la ciencia de datos requiere verla como una disciplina metodológica enfocada en la interpretación y extracción de conocimiento mediante técnicas computacionales y estadísticas. Su trayectoria histórica comienza con conceptos clásicos de análisis de datos y evoluciona hasta incorporar inteligencia artificial y automatización, transformando significativamente el perfil profesional requerido en el mercado actual.

1.2 Diferencia entre Data Scientist, Data Engineer y Data Analyst

Es fundamental distinguir los roles dentro de un equipo de datos:

• **Data Analyst:** Se centra en procesar, interpretar y visualizar datos para apoyar la toma de decisiones, transformando datos en informes accionables.

• **Data Scientist:** Utiliza estadística avanzada y modelado predictivo para extraer patrones complejos y anticipar tendencias.

• **Data Engineer:** Construye y mantiene la infraestructura necesaria (tuberías de datos, almacenamiento) para que los datos puedan ser procesados y gestionados en entornos productivos.

1.3 Metodologías

Para gestionar proyectos de ciencia de datos, existen marcos estructurados que guían desde la comprensión del negocio hasta la implementación. Entre las metodologías más comunes se encuentran CRISP-DM, SEMMA y KDD. Por ejemplo, CRISP-DM propone fases iterativas de entendimiento y preparación, mientras que SEMMA y KDD ponen un énfasis particular en la exploración y transformación de los conjuntos de datos.

1.4 Estructurados vs. No estructurados

La naturaleza de los datos dicta las herramientas a utilizar:

• **Datos Estructurados:** Organizados en tablas (filas y columnas), ideales para análisis con SQL y herramientas de Business Intelligence.

• **Datos No Estructurados:** Incluyen texto, imágenes o logs. No tienen un esquema fijo y requieren técnicas avanzadas como el Procesamiento de Lenguaje Natural (NLP) para su análisis,

1.5 Tipos de variables

La correcta identificación de las variables es crucial para la selección del modelo analítico:

• **Variables Cuantitativas:** Miden atributos numéricos (ej. edad, ingresos).

• **Variables Cualitativas:** Describen categorías o cualidades (ej. género, tipo de producto). Clasificar estas variables correctamente permite aplicar las transformaciones y técnicas estadísticas adecuadas.

1.6 Fuentes de datos

La riqueza del análisis depende de la integración de diversas fuentes, que pueden ser sistemas transaccionales, sensores, APIs web, redes sociales o repositorios abiertos. Es vital comprender las limitaciones de cada fuente en términos de calidad, formato y frecuencia de actualización, ya que esto impacta la confiabilidad de los resultados,

2. Fundamentos de programación para la ciencia de datos

La programación es la habilidad esencial para ejecutar análisis automatizados y manipular grandes volúmenes de datos. En este contexto, Python se ha consolidado como el lenguaje predominante debido a su versatilidad y a su robusto ecosistema de librerías científicas como NumPy y Pandas.

2.1 Entorno de Trabajo y Sintaxis Básica

El desarrollo suele realizarse en entornos interactivos como Jupyter Notebook o VS Code, que facilitan la escritura y depuración de código. La sintaxis básica de Python, que incluye reglas de indentación y asignación de variables, es el primer paso para desarrollar programas lógicos y libres de errores.

2.2 Variables y Tipos de Datos

Las variables en Python actúan como contenedores de valores que pueden cambiar. Los tipos de datos fundamentales incluyen:

• Enteros (integers)
• Flotantes (floats)
• Cadenas de texto (strings)
• Booleanos El manejo adecuado de estos tipos es esencial para evitar errores durante el procesamiento de datos en scripts automatizados.

2.3 Operadores: Aritméticos, Lógicos y de Comparación

Los operadores son las herramientas para manipular los datos:

• **Aritméticos:** Realizan cálculos matemáticos.

• **Lógicos y de Comparación:** Permiten tomar decisiones basadas en condiciones y evaluar relaciones entre valores, determinando el flujo de ejecución del programa según los criterios del analista.

2.4 Estructuras de Datos

Python ofrece estructuras versátiles para organizar colecciones de datos: listas, tuplas, diccionarios y conjuntos. El dominio de estas estructuras permite almacenar información de manera eficiente y aplicar transformaciones complejas necesarias en los proyectos de ciencia de datos.

2.5 Control de Flujo

Las estructuras de control de flujo, como los condicionales (if, else) y los bucles (for, while), regulan qué partes del código se ejecutan. Estos conceptos son indispensables para diseñar algoritmos que automaticen tareas repetitivas y se adapten dinámicamente a las características de los datos.

Bibliografía:

Menoyo Ros, D. García López, E. & García Cabot, A. (2021). *Fundamentos de la ciencia de datos:* (ed.). Editorial Universidad de Alcalá. https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/177631

Casas Roma, J. Nin Guerrero, J. & Julbe López, F. (2019). *Big data: análisis de datos en entornos masivos:* (ed.). Editorial UOC. https://elibro.unicartagenaproxy.elogim.com/es/ereader/unicartagena/117744?page=1

Holguín Londoño, G. A. Moreno Gallón, D. A. & Holguín Londoño, M. (2024). *Introducción a la ciencia y análisis de datos con Python: una visión empresarial:* (1 ed.). Editorial Universidad Tecnológica de Pereira. https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/287147

Casas Roma, J. Nin Guerrero, J. & Julbe López, F. (2019). *Big data: análisis de datos en entornos masivos:* (ed.). Editorial UOC. https://elibro.unicartagenaproxy.elogim.com/es/ereader/unicartagena/117744?page=1

Ramírez Jiménez, Ó. (2021). *Python a fondo:* (1 ed.). Marcombo. https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/280038

Marzal Varó, A. García Sevilla, P. & Gracia Luengo, I. (2016). *Introducción a la programación con Python 3:* (ed.). D - Universitat Jaume I. Servei de Comunicació i Publicacions. https://elibro.unicartagenaproxy.elogim.com/es/ereader/unicartagena/51760?page=1