Descripción Módulo De La Unidad 3

1. Conexión a Orígenes de Datos

La conexión a orígenes de datos es un paso inicial crítico en cualquier proyecto de ciencia de datos, ya que permite establecer enlace con fuentes diversas como bases SQL, APIs o archivos locales. Los profesionales deben aprender protocolos de acceso, autenticación y eficiencia para garantizar que los datos se integren de forma correcta para análisis posteriores.Esta competencia es esencial para gestionar datos reales en contextos productivos.

Además, comprender la conexión a los distintos orígenes habilita el uso de plataformas modernas como servicios web, portales de datos abiertos o sistemas transaccionales. Herramientas como Python y Power Query abstraen muchas complejidades técnicas y permiten a los principiantes interactuar con bases de datos relacionales o no relacionales. La capacidad de conectar y consultar eficientemente reduce errores y retrabajo.

Finalmente, un enfoque adecuado en la conexión de datos enfatiza la calidad y consistencia de las fuentes. Esta etapa requiere validación de credenciales, control de versiones y registro de metadatos, facilitando la trazabilidad de las transformaciones. Los estudiantes se benefician al practicar con distintos tipos de orígenes, preparando bases robustas para análisis avanzados en ciencia de datos

2. Herramientas: Excel, Power Query y Python

El manejo de herramientas es fundamental para ejecutar tareas de ETL (Extracción, Transformación y Carga). Microsoft Excel y Power Query permiten procesar datos sin necesidad de codificación avanzada, mientras que Python ofrece flexibilidad

para automatizar procesos complejos. Los estudiantes deben familiarizarse con cada herramienta para seleccionar la más adecuada según el volumen y complejidad de los datos.

Excel se mantiene como una herramienta accesible para tareas exploratorias y transformación básica, ideal para conjuntos de datos pequeños o medianos. Power Query, integrado en Excel y Power BI, habilita transformaciones más estructuradas mediante un interfaz visual, reduciendo errores y acelerando la limpieza de datos. Python, con librerías como pandas, permite escalabilidad y reproducibilidad en proyectos más complejos.

El entendimiento de estas herramientas no solo amplía la caja de herramientas del analista, sino que también promueve buenas prácticas de ingeniería de datos. Los futuros científicos de datos deben saber cuándo aplicar cada herramienta, considerando eficiencia, reproducibilidad y colaboración en equipos multidisciplinarios. Esto impacta directamente la calidad del análisis final.

3. Lectura y Escritura de Archivos (CSV, Excel, SQL, PDF, API, Web)

La lectura y escritura de varios formatos es una habilidad esencial, pues los datos provienen de fuentes heterogéneas. Los formatos comunes como CSV y Excel son universales, mientras que otros como PDF o fuentes web requieren técnicas de extracción más especializadas. Comprender estos formatos posibilita la ingesta eficiente de datos crudos en procesos de análisis.

Por su parte, el acceso a bases de datos SQL implica conocer estructuras de tablas, sentencias SELECT y filtros. Las APIs y web scraping amplían la capacidad de obtener datos de internet en tiempo real o periódicamente. Esto exige que los estudiantes dominen tanto conexiones como formatos de respuesta como JSON o XML para integrarlos en pipelines de datos.

Finalmente, la escritura hacia distintos destinos —ya sea un nuevo archivo CSV, una base de datos o un reporte PDF— permite confeccionar resultados reutilizables y compartir información con stakeholders. Esta etapa cierra el ciclo de ETL y prepara los datos para visualización y modelado. La automatización de estos flujos es una competencia valorada en ciencia de datos moderna.

4. Introducción a Pandas

Pandas es una librería de Python diseñada para manipulación eficiente de datos tabulares. Proporciona estructuras como DataFrames y Series que permiten filtrar, transformar y resumir información de forma expresiva y rápida. Para estudiantes de ciencia de datos, dominar pandas es esencial, pues facilita el manejo de grandes volúmenes de datos y la integración con otras librerías de análisis.

El uso de pandas incluye carga de datos, limpieza de valores faltantes, cambio de tipos y unificación de registros. Su sintaxis intuitiva permite operaciones complejas con pocas líneas de código, acelerando el proceso de análisis exploratorio. Además, pandas se integra con visualización y modelado, convirtiéndola en una herramienta central en cualquier flujo de trabajo de ciencia de datos.

Aprender pandas también implica comprender operaciones de transformación que preparan datos para modelos predictivos o reportes. El enfoque en eficiencia y legibilidad del código es clave para proyectos colaborativos. Por ello, los estudiantes practican casos reales que consolidan su comprensión y preparación para retos del mundo real.

5. Operaciones de Agregación

Las operaciones de agregación permiten sintetizar grandes conjuntos de datos en métricas significativas como promedios, sumas o conteos. Estas se aplican para

generar insights valiosos y respaldar decisiones informadas. En pandas, funciones como groupby, agg o pivot tables facilitan estos cálculos de forma eficiente, siendo una competencia indispensable para analistas.

Agrupar datos por categorías o periodos temporales permite identificar patrones y tendencias que no son evidentes a nivel individual. Estas operaciones habilitan comparaciones entre segmentos o análisis de variabilidad. La correcta aplicación de funciones agregadas fortalece la capacidad de presentar resultados claros a stakeholders.

Además, el dominio de agregaciones prepara al estudiante para técnicas más avanzadas de modelado y visualización, donde los datos resumidos actúan como entrada para algoritmos o dashboards. La capacidad de condensar información compleja en métricas interpretables es una habilidad central para cualquier científico de datos.

Bibliografía:

Raschka, S. & Mirjalili, V. (2019). Python Machine Learning: aprendizaje automático y aprendizaje profundo con Python, scikit-learn y TensorFlow: (2 ed.). Marcombo. https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/280024

Castillo Romero, J. A. (2019). Big data. IFCT128PO: (ed.). IC Editorial. https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/124254

López, A. & Rojas, A. L. (2021). *Introducción a Python para Estudiantes de Ciencias:* (1 ed.). Editorial UPTC. https://elibro.unicartagenaproxy.elogim.com/es/ereader/unicartagena/219225?page=1

Bruce, P. (Il.), Bruce, A. & Gedeck, P. (2022). *Estadística práctica para ciencia de datos con R y Python:* (2 ed.). Marcombo. https://elibro.unicartagenaproxy.elogim.com/es/lc/unicartagena/titulos/281858

Arévalo Ovalle, D. (2021). *Métodos numéricos con Python:* (1 ed.). Editorial Politécnico Grancolombiano. https://elibro.unicartagenaproxy.elogim.com/es/ereader/unicartagena/218585?page=1